

## 术语表

1. 矩阵统一用大写字母表示, 如 $A, X$ 标量用小写字母表示, 如 $x, y$ ;
  - 对于返回值是矩阵的函数, 同理应该为 $F(X)$ , 标量函数就记作 $f(x)$
  - 另外, 对于不混淆意思的 $x * 1$ 维度矩阵, 也就是**向量**, 允许用小写字母表示, 如 $x, y, x_i$
2. 对于矩阵的行列数, 统一用 $\{m, n\}$ 下标表示, 如 $A_{\{m, n\}}$

内参数矩阵 – **Camera Intrinsics** 15

外参数矩阵 – **Camera Extrinsics**: 一个 $3 * 4$ 的矩阵 $T$ ,

$$T = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix} T'$$

15

$\lambda$  – 特征值: 对于矩阵  $A$ , 如果满足

$$Ax = \lambda x$$

$\lambda$  就是  $A$  的特征值,  $x$  是特征向量

19

**linear space** – 线性空间 2

**Tr – 迹**:  $\text{Tr}$  表示矩阵的迹, 是用于求矩阵对角元素之和的算子

$$\text{Tr}[X] = \sum_i X_{ii}$$

18

# 数学知识杂烩

## 1 矩阵论

### 1.1 线性空间与线性变换

#### 1.1.1 线性空间

在矩阵论中, 将在线性代数的基础上, 推广向量空间 $R^n$ , 一般地定义线性空间的概念。这里参考杨明教授的《矩阵论》<sup>1</sup> 和 Strang, Gilbert 的《Linear Algebra and Its Applications》<sup>2</sup>。

**定义 1.1.1.1** (线性空间 (linear space)):  $V$  是一个非空集合,  $F$  是一个数域, 在其中定义两种运算, 加法( $\forall \alpha, \beta \in V, \alpha + \beta \in V$ )和数乘( $\forall k \in F, \alpha \in V, k\alpha \in V$ ), 如果满足若干运算法则, 就称 $V$ 是数域 $F$ 上的线性空间。

比如 $F_{\{n,1\}} = \{(x_1, x_2, \dots, x_n)^T \mid x_i \in F\}$  是  $F$  上的  $\{n, 1\}$  维线性空间。

$F_{\{n,m\}} = \{A = (a_{ij})_{\{m \times n\}} \mid a_{ij} \in F\}$  是  $F$  上的  $\{m, n\}$  维矩阵空间 记作  $R_{\{2,2\}}$ <sup>1</sup>

$P_n(x) = \{\sum_{i=0}^{n-1} a_i x_i \mid a_i \in R\}$  称为多项式空间  $P_{n[x]}$

**定义 1.1.1.2:** 如果对于线性空间 $V$  存在一组**线性无关**的向量 $(\alpha_1, \alpha_2, \dots, \alpha_n)$ , 使得空间中任意一个向量可以由它表示,  $(\alpha_1, \alpha_2, \dots, \alpha_n)$ 张成了向量空间, 此时有 $V$ 的维度

$$\dim(V) = n$$

**定义 1.1.1.3** (矩阵的逆): 如果对于向量 $A$ , 如果存在  $B$  使得  $AB = I$ , 则称  $B$  是  $A$  的逆矩阵, 记作  $A^{-1}$ , 并且说  $A$  是可逆的, 有时候也叫做非奇异矩阵<sup>2</sup>。并且

1.  $(AB)^{-1} = B^{-1}A^{-1}$
2.  $A$  的各列线性无关,  $\dim(A) = n$

---

<sup>1</sup>这里与教课书上 $R^{2 \times 2}$ 的写法不同, 读者注意。

<sup>2</sup>在数值运算中, 我们很少求解矩阵的逆, 计算他的计算量是行变换解方程的三倍<sup>2</sup>

## 1.1.2 内积空间

### 1.1.2.1 欧氏空间和酉空间

**定义 1.1.2.1.1:** 对数域 $F$ 上的线性空间 $V_n(F)$ ,定义一个从 $V_n(F)$ 到 $F$ 的二元运算 $(\alpha, \beta)$ , 记作 $(\alpha, \beta) : V_n(F) \rightarrow F$ , 满足以下条件

1.  $(\alpha, \beta) = (\beta, \alpha)$
2.  $(k\alpha, \beta) = k(\alpha, \beta)$
3.  $(\alpha, \alpha) \geq 0$ ,  $(\alpha, \alpha) = 0$ 仅当  $\alpha = 0$

我们就称这个二元运算是线性空间的一个内积, 并且定义了内积的线性空间称作内积空间 $[V_n(F); (\alpha, \beta)]$ 。如果 $F = R$  (实数域) 就称作欧氏空间; 如果 $F = C$  (复数域) 就称作酉空间。

下面举几个欧氏空间的例子

1.  $[\mathbb{R}^n; (\alpha, \beta) = \alpha^T \beta]$ , 习惯上, 我们直接将 $\mathbb{R}^n$ 记作欧氏空间。
2.  $[R_{\{n,n\}}; (A, B) = \text{Tr}[AB^T]]$
3.  $[P_n[x]; (f(x), g(x)) = \int_0^1 f(x) \cdot g(x) dx]$

**定义 1.1.2.1.2** ( $\|\alpha\|$ ): 在内积空间, 称

$$\|\alpha\| = \sqrt{(\alpha, \alpha)} = \alpha^T \alpha$$

为向量 $\alpha$ 的长度。在欧式空间中, 也称作**欧几里得范数**, 常表示为 $\|\alpha\|_2$ (注意下标)。下面给出几条它的性质

1. **(Cauchy 不等式)**  $|(\alpha, \beta)|^2 \leq \|\alpha\| \|\beta\|$
2.  $\|\alpha + \beta\| \leq \|\alpha\| + \|\beta\|$
3. 定义 $\alpha, \beta$ 夹角 $\theta = \arccos \frac{(\alpha, \beta)}{\|\alpha\| \|\beta\|}$

### 1.1.2.2 标准正交基

**定义 1.1.2.2.1:** 在 $V_n$ 中一组基 $\{\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n\}$ 满足

$$(\varepsilon_i, \varepsilon_i) = 0 \ \& \ \|\varepsilon_i\| = 1 \ \& \ (\varepsilon_i, \varepsilon_j) = 0 \quad 0 \leq i, j \leq n, i \neq j$$

就称作其为标准正交基。

从一组基 $\{\alpha_1, \alpha_2, \dots, \alpha_n\}$ 转换到标准正交基 $\{\beta_1, \beta_2, \dots, \beta_n\}$ 有

$$\beta_i = \alpha_i - \sum_{i=1}^{k-1} \frac{(a_k, \beta_i)}{(\beta_i, \beta_i)} \beta_i$$

证明方法参考<sup>1</sup> [p. 18], 这里略去。用矩阵的方式表示为

$$(\alpha_1, \alpha_2, \dots, \alpha_n) = (\beta_1, \beta_2, \dots, \beta_n) \begin{bmatrix} (\beta_1, \beta_1) & (\alpha_2, \beta_1) & \dots & (\alpha_n, \beta_1) \\ & (\beta_2, \beta_2) & \dots & (\alpha_n, \beta_2) \\ & & \dots & \dots \\ & & & (\beta_n, \beta_n) \end{bmatrix} \quad (1.1)$$

### 1.1.2.3 线性变换

**定义 1.1.2.3.1 (线性变换):** 如果存在一个单射  $T: V_n(F) \rightarrow V_n(F)$ , 满足

$$1. T(\alpha + \beta) = T(\alpha) + T(\beta)$$

$$2. T(k\alpha) = kT(\alpha)$$

就称  $T$  是一个  $V_n(F)$  上的线性变换。

**定义 1.1.2.3.2 (线性变换的矩阵):**  $\forall \alpha \in V_n(F)$ , 取一组基  $\{\alpha_1, \alpha_2, \dots, \alpha_n\}$

$$\alpha = x_1\alpha_1 + x_2\alpha_2 + \dots + x_n\alpha_n$$

$$[T(\alpha_1) \ T(\alpha_2) \ \dots \ T(\alpha_n)]^T = A^T [\alpha_1 \ \alpha_2 \ \dots \ \alpha_n]^T$$

称  $A$  为基  $\{\alpha_1, \alpha_2, \dots, \alpha_n\}$  下的矩阵。

**定理 1.1.2.3.1:** 如果  $\{\alpha_1, \alpha_2, \dots, \alpha_n\}$  到  $\{\beta_1, \beta_2, \dots, \beta_n\}$  有过渡矩阵  $C$

$$\text{其中 } [\alpha_1 \ \alpha_2 \ \dots \ \alpha_n] = [\beta_1 \ \beta_2 \ \dots \ \beta_n]C$$

, 同时在两组基下的矩阵分为为  $A, B$ , 则有

$$B = C^{-1}AC$$

**定义 1.1.2.3.3 (不变子空间):** 如果  $T$  是  $V_n(F)$  上的线性变换,  $W$  是  $V_n(F)$  的一个子空间, 如果  $T(W) \in W$ , 就称  $W$  是  $T$  的不变子空间。

**定义 1.1.2.3.4 (正交变换):** 如果  $T$  是  $V_n(F)$  上的线性变换, 且满足  $\forall \alpha, \beta \in V_n(F), (T(\alpha), T(\beta)) = (\alpha, \beta)$ , 就称  $T$  是正交变换。当空间是欧式空间就叫做正交变换, 其对应矩阵我们叫做正交矩阵  $C$ , 酉空间就叫做酉变换, 其矩阵叫做酉矩阵  $U$ 。

## 1.2 Jordan 标准形

### 1.2.1 Jordan 标准形及其求解

形如  $J(\lambda) = \begin{bmatrix} \lambda & 1 & & \\ & \lambda & 1 & \\ & & \ddots & 1 \\ & & & \lambda \end{bmatrix}$  的矩阵叫做  $r$  阶 Jordan 块, 若干个 Jordan 块组成的矩阵叫做 Jordan 矩阵, 如下

$$J = \begin{bmatrix} J_1(\lambda_1) & & \\ & J_2(\lambda_2) & \\ & & \ddots \\ & & & J_m(\lambda_n) \end{bmatrix}$$

在复数域上，每个方阵矩阵都可以相似于 Jordan 矩阵，并且唯一（若不计较 Jordan 的排列次序），即  $A = S^{-1}JS$ ，其中  $S$  是可逆矩阵， $J$  是 Jordan 矩阵。

**定义 1.2.1.1 (特征值和特征向量):** 对于定义在  $E$  上的变换  $T$ ，如果  $\exists \lambda$

$$T(\mu) = \lambda\mu$$

这里的  $\lambda$  就是  $T$  的特征值， $\mu$  是特征向量。

**定义 1.2.1.2 (直和  $\oplus$ ):**

$$A \oplus B = \begin{bmatrix} A & 0 \\ 0 & B \end{bmatrix} = \text{diag}(A, B)$$

**定义 1.2.1.3 (矩阵的核  $\text{Null}(A)$ ):**

$$\text{Null}(A) = \{v \in V : Av = 0\}.$$

**定理 1.2.1.1 (秩-零化度定理):**  $\text{rank } A + \text{nullity } A (\text{A 的特征值空间维度}) = n$

$$[A|E]^T = \begin{bmatrix} 1 & 2 & 3 & 1 & 0 & 0 \\ 1 & 1 & 1 & 0 & 1 & 0 \\ 0 & 1 & 1 & 0 & 0 & 1 \end{bmatrix}$$

对其做行初等变换，将  $A$  的下几行消元成 0，对应的右边行即为一个解。可以理解为其核空间每一个维度可以消解  $A$  空间一个冗余维度。

首先我们可以求解出其所有特征值。

$$|\lambda I - A| = \sum_{i=0}^k (\lambda - \lambda_i)^{\text{代数重数 } g_i} (a_i)$$

然后对于每一个特征值,  $\dim(\text{Null}(\lambda_i I - A))$  是多少就有多少 jordan 块，同时我们也要求解出其核空间的向量, 记作  $x$ , 然后使用 jordan 链进行递归求解直到无解, 求解每一个 jordan 块的大小。

$$A \begin{bmatrix} p_1 & p_2 & p_3 & p_4 \end{bmatrix} = \begin{bmatrix} p_1 & p_2 & p_3 & p_4 \end{bmatrix} \begin{bmatrix} \lambda & 1 & 0 & 0 \\ 0 & \lambda & 1 & 0 \\ 0 & 0 & \lambda & 1 \\ 0 & 0 & 0 & \lambda \end{bmatrix} = \begin{bmatrix} \lambda p_1 & \lambda p_2 + p_1 & \lambda p_3 + p_2 & \lambda p_4 + p_3 \end{bmatrix}$$

$$(A - \lambda E)p_1 = 0 \quad (1)$$

$$(A - \lambda E)p_2 = P_1 \quad (2)$$

...

$$(A - \lambda E)p_n = P_{n-1} \quad (n)$$

上式叫做 jordan 链, 直到  $(k+1)$  无法解出。则这个特征向量对应的 jordan 块的大小确定。

**例 1.2.1.1:** 求可逆矩阵  $P$  和 jordan 矩阵  $J$  使得  $A = P^{-1}JP$

$$A = \begin{bmatrix} -3 & 3 & -2 \\ -7 & 6 & -3 \\ 1 & -1 & 2 \end{bmatrix}$$

$|\lambda I - A| = 0 \Rightarrow (\lambda - 1)(\lambda - 2)^2$ , 确定其有两个 jordan 矩阵  $J_1, J_2$  组成, 对于  $J_1$ , 向量  $\alpha_1 = [1 \ 2 \ 1]^T$ 。

求解  $(2I - A)x = 0$ , 只有一个特征向量  $\alpha_2 = [-1 \ -1 \ 1]^T$ , 所以  $J_2$  只由一个 jordan 块构成。根据 jordan 链求出  $\beta_1 = (-1, -2, 0)^T$ 。所以得

$$P = [\alpha_1 \ \alpha_2 \ \beta_1]$$

## 1.2.2 最小多项式

**定义 1.2.2.1 (矩阵多项式):** 首先定义  $g(\lambda) = \sum_{i=0}^m a_i \lambda^i$ , 那么就可以定义矩阵  $g(A) = \sum_{i=0}^m a_i A^i$  为  $A$  的矩阵多项式。给出如下性质

1.  $Ax = \lambda x \Rightarrow g(A)x = g(\lambda)x$
2.  $P^{-1}AP = B \Rightarrow P^{-1}g(A)P = g(B)$
3.  $A = \text{diag}(A_1, A_2, \dots, A_n) \Rightarrow g(A) = \text{diag}(g(A_1), g(A_2), \dots, g(A_n))$
4.  $A$  的特征多项式  $(f(\lambda) = |\lambda I - A| = \sum_{i=0}^m a_i \lambda^i)$  就是  $A$  的化零多项式  $(g(A) = 0)$ 。

证 of 4: 左式  $\lambda$  换  $A$ 。 ■

**例 1.2.2.1 (求  $A^m$ ):** 假设  $g(A) = A^m \Rightarrow g(\lambda) = \lambda^m = \text{Hl}(\lambda) + \sum b_i \lambda_i \Rightarrow g(A) = \sum b_i A_i$

**定义 1.2.2.2 (最小多项式):**  $A$  的所有化零多项式中次数最低,  $a_0 = 0$  (首项系数为零) 的最小多项式, 记作  $m_r(\lambda)$ 。和特征多项式有相同的根, 重数可以不同。

**定理 1.2.2.1:** 一个矩阵可以对角化的充分必要条件是  $m_r(\lambda)$  的所有重数为 1。

$$m_r(\lambda) = \prod (\lambda - a_i) \quad a_i \text{ 互不相等}$$

## 1.3 矩阵分解

### 1.3.1 常见

#### 1.3.1.1 矩阵的三角分解

设  $A \in F_{\{n,n\}}$

1.  $L, U \in F_{\{n,n\}}$  分别为下三角和上三角矩阵,  $A = LU$  称作  $LU$  分解
2.  $L, V \in F_{\{n,n\}}$  分别为对角元素为 1 的下三角和上三角矩阵,  $D$  是对角矩阵, 称作  $LDV$  分解

**例 1.3.1.1.1** (求解  $P = \begin{bmatrix} 2 & 2 & 3 \\ 4 & 7 & 7 \\ -2 & 4 & 5 \end{bmatrix}$  的  $LU$  和  $PDV$  分解): 这里简单给出一个定理,

$$\begin{array}{c} \text{行初等变换} \uparrow \\ H[P|E] = [HP|P] \end{array} \quad \begin{bmatrix} P \\ - \\ E \end{bmatrix} L = \begin{bmatrix} PL \\ - \\ \text{列初等变换} \uparrow L \end{bmatrix}$$

将其写成增广矩阵  $[P \mid E] \Rightarrow [U \mid L']$ , 做行初等变换将  $P$  消成上三角矩阵。  $L'A = U \Rightarrow A = (L')^{-1}U = LU$

对  $U$  建立  $\begin{bmatrix} P \\ - \\ E \end{bmatrix}$ , 做列初等变换,  $\begin{bmatrix} P \\ - \\ E \end{bmatrix} \Rightarrow \begin{bmatrix} D \\ - \\ V' \end{bmatrix}$ , 有  $UV' = D \Rightarrow U = D(V')^{-1} =$   
 $DV$

接下来我们将分析一个矩阵有  $LU, LDV$  分解的条件, 并且注意, 矩阵的  $LDV$  分解并不唯一。

对于  $A$ , 设  $k$  阶顺序余子式  $\Delta_i = |A_{[0:i;0:i]}|$ , 如果  $\text{Rank}(A) = k$ , 其  $1-k$  阶顺序余子式不为 0, 则可  $LU$  分解,  $1$  到  $(n-1)$  阶顺序余子式不为 0, 则可  $LDV$  分解。

#### 1.3.1.2 满秩分解

**定理 1.3.1.2.1** ( $R_{\text{行}}(A) = R_{\text{列}}(A) = R(A)$ ): 行的秩表示为行向量张成向量空间的维度, 列的秩表示为列向量张成向量空间的维度。

证: 根据高斯变换, 得到行的秩等于主元个数等于列空间维度。 ■

**定理 1.3.1.2.2:** 任意不为零的矩阵  $A_{\{m,n\}}$  都有满秩分解

$$A_{\{m,n\}} = B_{\{m,r\}} C_{\{r,n\}}$$

求解方法①  $B'[A \mid E] \Rightarrow [\overset{\text{行阶梯型}}{C'} \mid B'] \Rightarrow A = [B_{\{m,r\}} \mid 0_{\{m,n-r\}}] \begin{bmatrix} C_{\{r,n\}} \\ 0_{\{n-r,n\}} \end{bmatrix} = B_{\{m,r\}} C_{\{r,n\}}$

② 先化为 Hermite 标准形  $H$  (带主元行阶梯型), 找到  $A$  中主元列取出构成  $B = (\alpha_1, \alpha_2, \dots, \alpha_n)$ ,  $H$  中非零行构成  $C$

### 1.3.1.3 可对角化矩阵的谱分解

$$A = P^{-1} \text{diag}(\underbrace{\lambda_1, \dots, \lambda_1}_{r_1 \uparrow}, \lambda_2, \dots, \underbrace{\lambda_n}_{r_n \uparrow}) P = \underbrace{P^{-1} \sum (\lambda_i I_{r_i}) P}_{\text{谱分解}}$$

其中  $\lambda_i$  表述矩阵的特征值,  $r_i$  表示特征值的重数。并且我们有

$$\sum I_{r_i} = E \quad \& \quad I_{r_i} I_{r_j} = 0 (i \neq j) \quad \& \quad I_{r_i}^2 = I_{r_i} \quad \& \quad I_{r_i}^T = I_{r_i}$$

### 1.3.2 Schur 分解与正规矩阵

**定理 1.3.2.1 (UR 分解):** 对于一个可逆矩阵  $A$ , 存在

$$A = U (\text{可逆矩阵}) R (\text{上三角矩阵})$$

证: 根据式(1.1), 可知 ■

**定理 1.3.2.2:** 如果  $A$  列满秩, 则

$$A_{\{m,k\}} = Q_{\{m,k\}} R_{\{k,k\}} \quad Q \text{ 的列向量是 } A \text{ 列空间的标准正交基}$$

**定义 1.3.2.1 (正规矩阵):** 对于矩阵  $A_{\{m,n\}}$ , 如果  $A^H A = A A^H$  就称  $A$  是正规矩阵。

常见的对角矩阵, 对称反对称 ( $A^T = \pm A$ ), Hermite 矩阵与反 Hermite 矩阵 ( $A^H = \pm A$ ), 正交矩阵与酉矩阵 ( $A A^T = A^T A = I, A A^H = A^H A = I$ ) 都是正规矩阵。



**定理 1.3.2.3:** 对于矩阵  $A_{\{n,n\}}$ , 其是正规矩阵的充要条件是  $A$  相似于对角矩阵, 即

$$\exists U_{\{n,n\}} \quad U^H A U = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_n)$$

推论充分必要条件

①  $A$  的特征向量是空间的标准正交基。

② 有谱分解  $A = \sum_{i=1}^s \lambda_i I_i$ ,

### 1.3.3 矩阵的奇异值分解

矩阵的奇异值分解是在线性动态系统的辨识, 最佳逼近问题, 实验数据处理, 数字图像处理存储中应用广泛的一种分解。

**定理 1.3.3.1:** 对于  $AA^H \in C_{\{m,n\}}$   $A^H A \in C_{\{m,n\}}$ , 有如下性质

1.  $\text{Rank}(AA^H) = \text{Rank}(A^H A) = \text{Rank}(A)$  (Use 定理 1.3.1.2.1)
2.  $\lambda_i \neq 0$ ,  $AA^H x = \lambda_i x \Rightarrow A^H A x = \lambda_i x$
3. 均为半正定矩阵, 行满秩  $(AA^H)_{\{m,m\}}$  正定, 列满秩  $(A^H A)_{\{n,n\}}$  正定。

证 of 2:  $|AA^H - \lambda_i E| = 0 = |(AA^H - \lambda_i E)^T| = |A^H A - \lambda_i E|$  ■

**定义 1.3.3.1 (奇异值):** 对于矩阵  $A_{\{m,n\}}$ , 其奇异值是  $AA^H$  的特征值的平方根

$$\sigma_i = \sqrt{\lambda_i} \quad \& \quad (AA^H)x = \lambda_i x$$

其奇异值个数等于矩阵的秩。

**定理 1.3.3.2:** For  $A_{\{m,n\}}$ , 其奇异值可分解为

$$A = U_{\{m,m\}} \Sigma_{\{m,n\}} V_{\{n,n\}}^H$$

其中  $U, V$  是酉矩阵,

$$\Sigma = \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_w) \oplus 0_{\{m-w, n-w\}} \quad \& \quad w = \text{rank}(A^H A) \quad \& \quad \sigma_i \neq 0$$

证: 对于  $A^H A$  因为其是半正定矩阵, 所以有

$$V^H A^H A V = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_k) \oplus 0$$

其中  $V = [v_1 \ v_2 \ \dots \ v_n]$  是  $A^H A$  标准正交的特征向量

$$\begin{aligned}
(Av_i, Av_j) &= (Av_j)^H Av_i = v_j^H (A^H Av_i) = v_j^H (\lambda_i v_i) = \lambda_i \begin{pmatrix} 0 & i \neq j \\ 1 & i = j \end{pmatrix} v_j^H v_i \\
&= 0 \quad (i \neq j) \\
&= \lambda_i = \sigma_i^2 \quad (i = j, \lambda_i \neq 0)
\end{aligned}$$

设  $u_i = \frac{1}{\sigma_i} Av_i \Rightarrow Av_i = \sigma_i u_i \quad i = 1, 2, \dots, \text{rank}(A)$ . 所以

$$\begin{aligned}
AV &= A[v_1 \ v_2 \ \dots \ v_n] = [\sigma_1 u_1 \ \sigma_2 u_2 \ \dots \ \sigma_r u_r \ 0 \ \dots \ 0] \\
&= [u_1 \ u_2 \ \dots \ u_r \ 0_{\{1, n-r\}}] \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_r, 0, \dots, 0) \\
A &= U \begin{bmatrix} \Delta & \\ & 0 \end{bmatrix} V^{-1} = U \Sigma V^H = \sum_{i=1}^r (u_i \sigma_i v_i^H)
\end{aligned}$$

后面这一项可以取  $k < r$ , 做近似压缩。 ■

**定理 1.3.3.3 (极分解):** 对于  $A_{\{n,n\}}$ , 有  $A = P_{\{n,n\}}$  (半正定)  $Q_{\{n,n\}}$  (酉矩阵)

证:  $A = U \Sigma V^H = U \Sigma (E) V^H = U \Sigma (U^H U) V^H = (U \Sigma U^H) (U V^H) = P Q$  ■

$P$  是缩放,  $Q$  是旋转。所以得名极分解。

**定义 1.3.3.2 (对称、实对称、正定、半正定、海森矩阵):**

| 名称             | 定义   | 注释                       |
|----------------|--|--------------------------|
| 实对称矩阵          | $A \in \mathbb{R}^{n,n} \quad A = A^T$                           | 反对称 $A = -A^T$           |
| Hermite(厄米特)矩阵 | $A \in \mathbb{C}^{n,n} \quad A = A^H$                           | 反 Hermite $A = -A^H$     |
| 正交矩阵           | $T \in \mathbb{R} \quad (\alpha, \beta) = (T(\alpha), T(\beta))$ | $AA^T = E, A^{-1} = A^T$ |
| 酉矩阵            | $T \in \mathbb{C} \quad (\alpha, \beta) = (T(\alpha), T(\beta))$ | $A^H A = AA^H = E$       |
| 正规矩阵           | $AA^H = A^H A$   | 与正交矩阵相似的矩阵               |
| 正定矩阵           | $\forall x \in \mathbb{R}^n, x^T A x > 0$                        | 正定矩阵的特征值都是正的             |
| 半正定矩阵          | $\forall x \in \mathbb{R}^n, x^T A x \geq 0$                     | 特征值都是非负的                 |
| 海森矩阵           | $H_{\{i,j\}} = \frac{\partial^2 f}{\partial x_i \partial x_j}$   | 二阶偏导数矩阵                  |

### 1.3.3.1 最小二乘应用

参考<sup>3</sup>, 我们简述其在最小二乘问题上的应用。考虑

$$\min \|Ac - y\|_2 \quad (A \text{ 为数据矩阵 } c \text{ 为参数矩阵})$$

比如对于  $f(x) = c_1x + c_2x^2 + c_3x^3$

$$A = \begin{bmatrix} x_1 & x_1^2 & \dots & x_1^3 \\ x_2 & x_2^2 & \dots & x_2^3 \\ \dots & \dots & \dots & \dots \\ x_n & x_n^2 & \dots & x_n^3 \end{bmatrix} \quad \& \quad c = \begin{bmatrix} c_1 \\ c_2 \\ \dots \\ c_n \end{bmatrix} \quad y = \begin{bmatrix} y_1 \\ y_2 \\ \dots \\ y_n \end{bmatrix}$$

首先我们知道  $A = U \Sigma V^H$  &  $U$  是酉矩阵,  $\|U\| = 1$ , 所以

$$\begin{aligned} \|y - Ac\|_2^2 &= \|U^H(y - Ac)\|_2^2 = \|U^H(y - U \Sigma V^H c)\|_2^2 \\ &= \|U^H y - \Sigma V^H c\|_2^2 = \|D - \Sigma Z\|_2^2 \\ &= \left\| \begin{pmatrix} d_1 & d_2 & \dots & d_n \end{pmatrix}^T - \begin{pmatrix} \sigma_1 z_1 & \dots & \sigma_r z_r & 0_{\{1, n-r\}} \end{pmatrix}^T \right\|_2^2 \\ &= \left\| \begin{pmatrix} d_1 - \sigma_1 z_1 & d_2 - \sigma_2 z_2 & \dots & d_r - \sigma_r z_r & d_{r+1} & \dots & d_n \end{pmatrix}^T \right\|_2^2 \\ &= \sum_{i=1}^r (d_i - \sigma_i z_i)^2 + \sum_{i=r+1}^n d_i^2 \end{aligned}$$

因为  $A = U \Sigma V^H$   $A$  为定值,  $U, \Sigma, V_H$  也为定值, 所以  $d$  也为定值

$$\min \|y - Ac\|_2^2 = \min \sum_{i=1}^r (d_i - \sigma_i z_i)^2 \Rightarrow z_i = \frac{d_i}{\sigma_i} \quad \& \quad (i = 1, 2, \dots, r)$$

$$V^H c_i = z_i \rightarrow c_i = V z_i \quad \& \quad (i = 1, 2, \dots, r)$$

并且  $[r_1, n]$  的  $c_i$  不影响, 可任取。

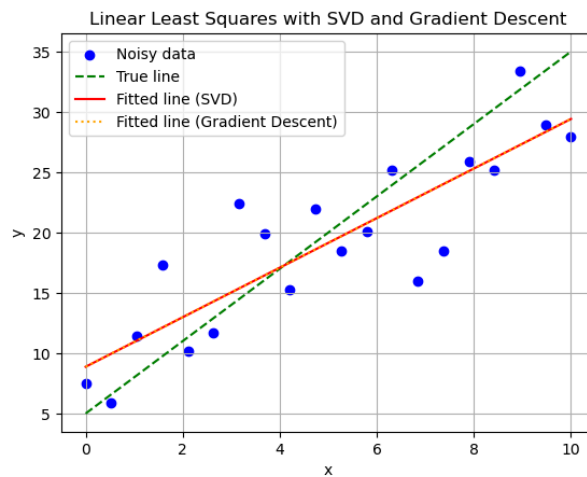


图 1.1: 通过 SVD 求解线性最小二乘问题的例子并和梯度下降法比较

<sup>3</sup>L2 范数表示欧几里得空间上符合直觉的向量长度  $\|x\|_2 = \sqrt{x^T x} = \sqrt{x_1^2 + x_2^2 + \dots + x_n^2}$

## 1.4 矩阵的广义逆

### 1.4.1 减号广义逆

定义 1.4.1.1 (逆的推广): for  $A_{\{m,n\}}$

$$A_{\{m,m\}}^{-1} A_{\{m,n\}} \quad (\text{左逆}) \quad A_{\{m,n\}} A_{\{n,n\}}^{-1} \quad (\text{右逆})$$

左逆列满秩( $m \geq n$ ), 右逆行满秩( $m \leq n$ )。

$$(\text{左逆求解}) P_{\{n,m\}} [A_{\{m,n\}} \quad E_{\{m,m\}}] = [E_{\{m,m\}} \quad \dots \quad P_{\{m,m\}}] = \begin{bmatrix} E_{\{m,m\}} & \dots & P_{\{m,m\}} \\ & & \dots \end{bmatrix}$$

$$(\text{右逆求解}) \begin{bmatrix} A_{\{m,n\}} \\ E_{\{n,n\}} \end{bmatrix} P_{\{n,m\}} = \begin{bmatrix} E_{\{m,m\}} \\ \dots \\ P_{\{n,n\}} \end{bmatrix} = \begin{bmatrix} E_{\{m,m\}} \\ \dots \\ P_{\{n,m\}} \quad \dots \end{bmatrix}$$

定义 1.4.1.2 (减号广义逆): 对于  $A_{\{m,n\}} \in \mathbb{C}^{n,n}$  存在  $G_{\{n,m\}} \in \mathbb{C}^{n,n}$  使得  $AGA = A$ , 就称  $G$  是  $A$  的减号广义逆。  $G \in A\{1\}$  &  $A\{1\} = \{A_1^-, A_2^-, \dots, A_n^-\}$

$G \in A\{1\}$  的充分必要条件

$$PAQ = \text{diag}(I_r, 0) \quad \& \quad G = Q \begin{bmatrix} I_r & U \\ V & W \end{bmatrix} P \quad \& \quad UVW \text{ 大小合适, 任意矩阵}$$

$$\text{证: ①必要性, } P(AGA)Q = \text{diag}(I_r, 0) \begin{bmatrix} I_r & U \\ V & W \end{bmatrix} \text{diag}(I_r, 0) = \text{diag}(I_r, 0) = PAQ$$

$$\text{②充分性 } PAQ = P(AGA)Q = \text{diag}(I_r, 0) Q^{-1} G P^{-1} \text{diag}(I_r, 0) = \text{diag}(I_r, 0)$$

$$\begin{bmatrix} I_r & 0 \\ 0 & 0 \end{bmatrix} Q^{-1} G P^{-1} \begin{bmatrix} I_r & 0 \\ 0 & 0 \end{bmatrix} = \begin{bmatrix} I_r & 0 \\ 0 & 0 \end{bmatrix} \Rightarrow Q^{-1} G P^{-1} = \begin{bmatrix} E_{\{r,r\}} & U \\ V & W \end{bmatrix}$$

$$\text{所以 } G = Q \begin{bmatrix} E_{\{r,r\}} & U \\ V & W \end{bmatrix} P \quad \blacksquare$$

至于求解过程就是

$$\begin{bmatrix} A_{\{m,n\}} & E_{\{m,m\}} \\ E_{\{n,n\}} & 0 \end{bmatrix} \Rightarrow (\text{做行列初等变换}) \Rightarrow \begin{bmatrix} \text{diag}(E_r, 0) & P_{\{m,m\}} \\ Q_{\{n,n\}} & 0 \end{bmatrix}$$

### 1.4.2 M-P 逆

定义 1.4.2.1 (M-P 逆): 对于  $A_{\{m,n\}}$ , 其 M-P 逆  $A^+ = G$ , 有(任意矩阵都存在, 并且唯一)

$$AGA = A \quad \& \quad GAG = G \quad \& \quad (AG)^H = AG \quad \& \quad (GA)^H = GA$$

不做具体赘述了, 记住在 python 中可以使用 `np.linalg.pinv` 求解就足够了。

定理 1.4.2.1 (最佳的最小二乘解):

$$\min \|Ax - b\|_2^2 = (x = A^+b)$$

## 1.5 矩阵分析

### 1.5.1 矩阵函数及其应用

## 1.6 计算机视觉中的应用

我们会用到的向量 $\in \mathbb{R}^2\mathbb{R}^3$ <sup>4</sup>。

### 1.6.1 $\mathbb{R}^3$ 中的变换 (相机相关)

**定义 1.6.1.1 (齐次坐标):** 对于 $n$ 维度向量 $x = (x_1, x_2, \dots, x_n)$ , 其在 $n + 1$ 维向量空间中的齐次向量 (坐标) 为 $(x_1, x_2, \dots, x_n, 1)^T$ , 称为 $n$ 维齐次坐标, 记作 $\tilde{x}$ 。他对于 $\mathbb{R}^2\mathbb{R}^3$ 中的变换非常有用, 它统一了旋转、平移和缩放。(但是注意齐次坐标并不能相加或者相乘, 只能乘以 $T_{\{n+1, n+1\}}$ 来做变换)。

比如对于一个向量 $p$ , 一个混合变换 $p' = Ap + t$ , 使用分块矩阵的知识, 也可以看作是

$$p' = \begin{bmatrix} A_{\{n, n\}} & t_{\{1, 1\}} \\ B_{\{1, n\}} & s_{\{1, 1\}} \end{bmatrix} \begin{bmatrix} p \\ 1 \end{bmatrix} = T \text{ Hm}(p) \quad \& (t = 0, B = 0_{\{1, n\}})$$

这里的 $T$ , 我们称作透视矩阵(Transform Matrix)。  $T$ 的第一行代表的是以 $(x, y, z)^T$ 为基的坐标系下的变化,  $T_{21}$ 一般直接以0,  $T_{22}$ 也可以表示缩放性质。

| 变换     | 条件  | 自由度 |
|--------|---|-----|
| 欧几里得变换 | $A = R \ \& \ s = 1 \ \& \ B = 0_{\{1, 3\}}$                    | 6   |
| 缩放变换   | $A = cR \ \& \ s = 1 \ \& \ B = 0_{\{1, 3\}}$                   | 7   |
| 纯缩放变换  | $A = cE \ \& \ s = 1 \ \& \ B = 0_{\{1, 3\}}, t = 0_{\{3, 1\}}$ | 1   |
| 仿射变换   | $s = 1 \ \& \ B = 0_{\{1, 3\}}$                                 | 15  |
| 射影变换   | None  | 12  |

#### 1.6.1.1 欧几里得变换、缩放变换

欧几里得变换包括绕原点旋转, 平移, 轴对称, 中心对称 (正交变换), 在欧几里得变换中的 $T_A$ 是正交矩阵, 只有三个自由度 (之后三维空间刚体变换会讲到)。

<sup>4</sup> $\mathbb{R}^n$ 表示  $n$  维向量空间

**定义 (正交矩阵):**<sup>4</sup> 正交矩阵(Orthogonal Matrix)是指矩阵的转置等于逆矩阵的矩阵, 也就是说 $A^{-1} = A^T$ , 并且可以推证 $|A| = 1$ 。 其中,  $\det(A) = 1$ 的时候叫做**旋转矩阵**,  $\det(A) = -1$ 的时候叫做**瑕旋转矩阵** (瑕旋转是旋转加上镜射。镜射也是一种瑕旋转)。所有 $A_{\{n,n\}}$ 构成一个**正交群**。

至于缩放变换呢,略去介绍。

### 1.6.1.2 小孔成像模型

我们直接推导一下基于小孔成像的相机模型, 也就是三维物体在二维计算机屏幕上的表示。




图 1.2: 相机模型示意图

如图 2 中所示, 对于任意一点, 相当于关于原点的一个对称。对于大部分教程, 都教大家用相似三角形求解, 你可以在上图中寻找对应的三角形。诚然, 这就是一个**纯缩放变换**, 只要求出缩放系数 $c$ 可。

$$c = -\frac{f}{z_i}$$

在现代相机中, 我们对像做了预处理, 使得原本成倒像的小孔成像可以正确成像, 成像平面于  $A'^{(xy)}$  平面 (实际像平面), 所以实际上  $c_a = -c = \frac{f}{z_i}$ 。

同时我们定义像素坐标系如图中所示, 以  $O_c = (x_0, y_0, z_0 = f)^T$  为原点,  $x, y$  轴如图所示的坐标系 (实际上它应该定义在实际像平面上)。假设  $\alpha = c_a k_x, \beta = c_a k_y, \gamma = c_a k_z$ , ( $k_x, k_y$  为两个尺度因子, 表示从米变换为像素) 从  $P_i$  到  $P'_i$  有变换

$$\tilde{P}'_{i_a} = \begin{bmatrix} \alpha & 0 & 0 & x_0 \\ 0 & \beta & 0 & y_0 \\ 0 & 0 & \gamma & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix} \tilde{P}_i$$

实际像平面

定义  $u = \tilde{P}'_{i_a}(0), v = \tilde{P}'_{i_a}(1)$

$$\begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = \begin{bmatrix} \frac{\alpha}{z_i} & 0 & x_0 \\ 0 & \frac{\beta}{z_i} & y_0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x_i \\ y_i \\ 1 \end{bmatrix} = \begin{bmatrix} \frac{\alpha}{z_i} & 0 & \frac{x_0}{z_i} \\ 0 & \frac{\beta}{z_i} & \frac{y_0}{z_i} \\ 0 & 0 & \frac{1}{z_i} \end{bmatrix} \begin{bmatrix} x_i \\ y_i \\ z_i \end{bmatrix} = \frac{1}{z_i} \begin{bmatrix} \alpha & 0 & x_0 \\ 0 & \beta & y_0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x_i \\ y_i \\ z_i \end{bmatrix} = \frac{1}{z_i} K p_i$$

$c$  缩放因子<sup>5</sup>  
Camera Intrinsics (内参数矩阵)

同时我们的相机平面并不一定这么理想，它可能是各种姿态，我们需要先将初始的  $p_i^s$  转换到可以求解

$$p_i = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix} \tilde{p}_i = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix} T' p_i^s = T_{\{3,4\}} \tilde{p}_i^s$$

我们将这里的  $T_{\{3,4\}}$  称作相机的 Camera Extrinsics (外参数矩阵)。综上所述有

$$\begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = \frac{1}{z_i} K T \tilde{p}_i^s = K T \begin{bmatrix} \frac{x_i}{z_i} \\ \frac{y_i}{z_i} \\ 1 \end{bmatrix}$$

位于归一化平面

### 1.6.1.3 畸变模型

我们先来简单介绍一下几何光学中的成像模型以及像差理论。<sup>5</sup>

实际的光学系统总是与理想的光学系统存在很大差异 (如不同的孔径和视场)，一个物点发出的光线经过实际光线汇聚后，其实不再汇聚于一点，而是一个**弥散斑**。对于单色光而言，从几何光学的角度分析，常见的像差有球差，惠差，场曲，畸变，像散。

其中，只有畸变影响几何形状，其他像差影响成像的清晰度 (这个我们无能为力，选择好的镜头，合适的焦距，孔径，使用距离)。

畸变分为径向畸变 (由透镜形状引起的畸变) 和切向畸变 (透镜和 CCD 不共面导致的畸变)

<sup>5</sup> 【缩放因子  $c$ 】代表图像轴  $u, v$  的非垂直性, 表示  $u, v$  的夹角偏离  $90^\circ$  的情况。理想情况下，图像平面上的  $x$  轴和  $y$  轴是垂直的  $c = 0$ ，但在某些特殊情况下，可能由于镜头设计或制造偏差，它们并非严格垂直。一般来说它等于 0，Opencv 中也是将其设置为 0 进行的标定。




图 1.3: 径向畸变的几种类型(b)枕形畸变 (c)桶形畸变




图 1.4: 切向畸变产生原因

我们将 $(u, v)^T$ 表示成极坐标形式, 即 $(r, \theta)^T$ 。

对于径向畸变而言, 主要是随着 $r$ 的增大, 畸变程度增大, 其矫正公式如下(使用 $k_1$ 就足够)

$$x_{corrected} = x(1 + k_1 r^2 + k_2 r^4 + k_3 r^6)$$

$$y_{corrected} = y(1 + k_1 r^2 + k_2 r^4 + k_3 r^6)$$

对于切向畸变, 引入 $p_1, p_2$

$$x_{corrected} = x + 2p_1 xy + p_2(r^2 + 2x^2)$$

$$y_{corrected} = y + p_1(r^2 + 2y^2) + 2p_2 xy$$

然后通过相机标定标定相机内参和畸变系数即可。

#### 1.6.1.4 双目相机

单个相机是无法确定 $z$ 的, 通常我们采用双目相机或者 RGBD 相机来解决这个问题。双目相机的原理是显然的, 对于单个相机, 我们能确定图像上一点在相机坐标系下一条直线上, 只要两个直线有交点, 物点可知。



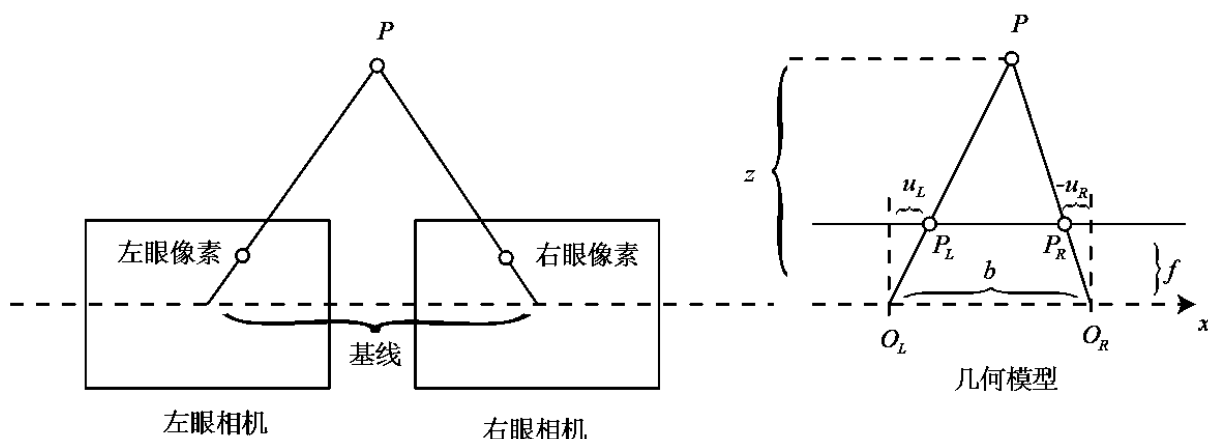


图 1.5: 双目相机原理

双目相机一般由左眼和右眼两个水平放置的相机组成, 如上图所示。根据相似三角形原理,

$$\frac{z-f}{z} = \frac{b - U_L + U_R}{b} \Rightarrow z = \frac{fb}{d}, \quad d = u_L - u_R.$$

这里  $d$  为左右图的横坐标之差, 称为视差(Disparity), 求解它需要知道左边相机像素在右边相机上对应哪一个位置。

## 1.6.2 李群和李代数

**定义 1.6.2.1 (群):** 一个集合  $G$  和一个二元运算  $*$ , 如果满足以下条件, 就称  $G$  是一个群。

1. 封闭性: 对于任意  $a, b \in G$ , 有  $a * b \in G$
2. 结合律: 对于任意  $a, b, c \in G$ , 有  $(a * b) * c = a * (b * c)$
3. 单位元: 存在一个元素  $e \in G$ , 使得对于任意  $a \in G$ , 有  $e * a = a * e = a$
4. 逆元: 对于任意  $a \in G$ , 存在一个元素  $b \in G$ , 使得  $a * b = b * a = e$

## 1.6.3 三维空间刚体变换

### 1.6.3.1 旋转矩阵

上一章节有详细的讲解, 掠过。

### 1.6.3.2 旋转向量

旋转矩阵有九个量, 但实际上作为正交矩阵, 它只有三个自由度, 并且还约束为正交矩阵, 有时会使求解变得困难。我们可以用旋转向量来表示旋转矩阵。

### 1.6.3.3 欧拉角

### 1.6.3.4 四元数

## 2 矩阵导数

### 2.1 基本介绍

从一个最基本的函数  $f(x) = ax$  开始，显然

$$\frac{\partial}{\partial x} f(x) = a$$

拓展  $f(x) = \sum_i a_i x_i = a^T x$  &  $A = [a_1, a_2, \dots, a_n]^T$   $X = [x_1, x_2, \dots, x_n]$

$$\frac{\partial}{\partial \underset{\text{n维向量}}{x}} \overset{\text{标量}}{\sum_i^n a_i x_i} f(x) = \begin{bmatrix} \frac{\partial}{\partial x_1} f(x) \\ \frac{\partial}{\partial x_2} f(x) \\ \dots \\ \frac{\partial}{\partial x_n} f(x) \end{bmatrix} = \begin{bmatrix} a_1 \\ a_2 \\ \dots \\ a_n \end{bmatrix} = a \quad (2.2)$$

注意到这里  $\frac{\partial}{\partial x} f(x)$  的维度等于  $x$  的维度。那如果我们继续拓展呢？ $x$  是任意维度矩阵的时候，结果又会怎么样呢？

**定理 2.1.1:**  $\frac{\partial}{\partial X} f(x)$  应和  $X$  的行列数相同（ $f(x)$  是标量的时候），并且

$$\left[ \frac{\partial}{\partial X} f(x) \right]_{ij} = \frac{\partial}{\partial X_{ij}} f(x)$$

$$\frac{\partial f}{\partial X^T} = \frac{\partial f}{\partial X}^T \quad (2.3)$$

并且我们继续分析式(2.2) 它表明，至少对于我们给出的例子有  $\frac{\partial a^T x}{\partial x} = a$ ，那对于所有呢？显然它也成立

**定理 2.1.2:** 如果存在一个多元标量函数  $f(x) = \text{迹}(\text{Tr})[A^T X]$ ，那么

$$\left[ \frac{\partial f}{\partial X} \right] = A$$

**定理 2.1.3 (Tr 性质):** 我们给出一些关于迹的性质, 其中矩阵  $A$  和  $B$  的大小适当, 且  $c$  是一个标量值。

1.  $\text{Tr}[A + B] = \text{Tr}[A] + \text{Tr}[B]$
2.  $\text{Tr}[cA] = c \text{Tr}[A]$
3.  $\text{Tr}[AB] = \text{Tr}[BA] = \sum_{i=1}^n \sum_{k=1}^n A_{ik} B_{ki}$
4.  $\text{Tr}[A^T] = \text{Tr}[A]$
5.  $\text{Tr}[A_1 A_2 \dots A_n] = \text{Tr}[A_n A_{n-1} \dots A_1]$
6.  $\text{Tr}[A^T B] = \sum A_{ij} B_{ij}$
7.  $\text{Tr}[A] = \sum \text{特征值 } (\lambda)$
8.  $f(x) = \text{Tr}[f(x)] = \text{Tr}[f(x)^T]$  & When  $f(x)_{\{1,1\}}$

证 of 定理 2.1.3(3)  $\text{Tr}[AB] = \text{Tr}[BA]$ :

$$AB_{ij} = \sum_{k=1}^n A_{ik} B_{kj} \Rightarrow AB_{ii} = \sum_{k=1}^n A_{ik} B_{ki}$$

$$\sum_{i=1}^n \sum_{k=1}^n A_{ik} B_{ki} = \sum_{i=1}^n \sum_{k=1}^n B_{ik} A_{ki} \quad (2.4)$$

$ik$   $ki$ 的情况都会出现, 所以显然式(2.4) 成立, 证毕。 ■

## 2.2 标量矩阵导数 $f(x)$

### 2.2.1 矩阵微分

定义 2.2.1.1:

$$dX = \begin{bmatrix} dX_{11} & dX_{12} & \dots & dX_{1n} \\ dX_{21} & dX_{22} & \dots & dX_{2n} \\ \dots & \dots & \dots & \dots \\ dX_{n1} & dX_{n2} & \dots & dX_{nn} \end{bmatrix} \quad (2.5)$$

矩阵里面的每一个如  $dX_{11}$ , 其实

**定理 2.2.1.1:**

证:

$$d \text{Tr}[A] = \text{Tr}[dA]$$

$$\text{Tr}[dA] = \sum_i dA_{ii} = \sum_i dA_{ii} = d \sum_i A_{ii} = d \text{Tr}[A]$$

■

标量形式的微分和导数可以用下式表示

$$df = \frac{\partial f}{\partial x} dx$$

对于矩阵，有如下定理

**定理 2.2.1.2:**

$$df(X) = \text{Tr} \left[ \frac{\partial f}{\partial X}^T dX \right] \quad (2.6)$$

证: For 式(2.6)  $f(x) = \text{Tr}[f(x)] = \text{Tr}[f(x)^T] \quad (2.7)$

$$df(X) = \sum_{ij} \frac{\partial f}{\partial X_{ij}} dX_{ij}$$

使用式(2.4)

$$\begin{aligned} \text{Tr} \left[ \frac{\partial f}{\partial X}^T dX \right] &= \sum_i \sum_k \left[ \left( \frac{\partial f}{\partial X}^T \right)_{ik} (dX)_{ki} \right] \\ &= \sum_i \sum_k \left[ \left( \frac{\partial f}{\partial X} \right)_{ki} (dX)_{ki} \right] \end{aligned}$$

For 式(2.7),只需要意识到 $f(x)_{\{1,1\}}$ 即可。证毕。

■

**定理 2.2.1.3:** 对于矩阵微分，有如下几个性质及延伸性质

1.  $d(A + B) = d(A) + d(B)$
2.  $d(cA) = cd(A)$
3.  $d(AB) = d(A)B + Ad(B)$

---

<sup>6</sup>这里的 $f(X)$ ,  $f$ 小写，应该为标量函数

4.  $d(X^T) = d(X)^T$
5.  $\frac{\partial x^T A x}{\partial x} = Ax + A^T x$
6.  $d(X^{-1}) = -X^{-1}dX X^{-1}$  (if  $X^{-1}$  exists)

证 of 3  $d(AB) = d(A)B + Ad(B)$ :

$$\begin{aligned}\text{LEFT} &= df(AB) = d \sum_k A_{ik} B_{ki} \\ &= \sum_k d(A_{ik}) B_{ki} + A_{ik} d(B_{ki})\end{aligned}$$

$$\text{RIGHT} = [d(A)B + Ad(B)]_{ij} = \sum_k d(A)_{ik} B_{ki} + \sum_k d(B)_{ik} A_{ki} = \text{LEFT}$$

■

证 of 4:  $d(X^T) = d(X)^T$ : 使用式(2.5)

■

证 of 5:  $\frac{\partial x^T A x}{\partial x} = Ax + A^T x$  :

$$\begin{aligned}d(x^T A x) &= d \text{Tr}[x^T A x] \\ &= \text{Tr}[d(x^T) A x + x^T d(A x)] \\ &= \text{Tr}[d(x)^T A x + x^T \underset{0}{d(A)} x + x^T Ad(x)]\end{aligned}$$

$$(\text{Tr}[A + B] = \text{Tr}[A] + \text{Tr}[B]) = \text{Tr}[d(x)^T A x] + \text{Tr}[x^T Ad(x)]$$

$$(\text{Tr}(A^T) = \text{Tr}[A]) = \text{Tr}[x^T A^T d(x)] + \text{Tr}[x^T Ad(x)]$$

$$\begin{aligned}\text{Then } \Rightarrow \frac{\partial x^T A x}{\partial x} &= (x^T A^T + x^T A)^T \\ &= Ax + Ax^T\end{aligned}$$

■

证 of 6  $dX^{-1} = -X^{-1}dX X^{-1}$ :

$$d(I) = 0 = d(XX^{-1}) = d(X)X^{-1} + Xd(X^{-1})$$

$$d(X^{-1}) = -X^{-1}d(X)X^{-1}$$

■

### 2.2.2 标量对矩阵求导的求解过程

从上面的例子中，我们可以得到对于一个  $f(x)$  求解  $\frac{\partial f(x)}{\partial x}$  的固定步骤

- 1  $df(x) = d \operatorname{Tr}[f(x)] = \operatorname{Tr}[df(x)]$  or  $df(x) = d \operatorname{Tr}[f(x)^T] = \operatorname{Tr}[df(x)^T]$   
| 见式(2.7)
- 2 使用定理 2.1.3 中关于 trace 的各种性质, 化简成  $\sum_i \operatorname{Tr}[U_i d(x)]$  的形式
- 3 如式(2.6), 所以  $\frac{\partial f(x)}{\partial x} = \sum_i (U_i)^T$

### 3 最优化理论

所谓最优化问题, 就是求解  $\min f(x) \ \& \ x \in K$

#### 3.1 最小二乘的几种解法

$$\min F(x) = \|f(x)\|_2^2 = \|b - Ax\|$$

##### 3.1.1 牛顿法

$$\begin{aligned} f(x) &= f(x_0)(x - x_0)^0 + f'(x_0)(x - x_0) + \left(\frac{f''(x_0)}{2!}\right)(x - x_0)^2 + \dots \\ &\approx f(x_0)(x - x_0)^0 + f'(x_0)(x - x_0) + \frac{f''(x_0)(x - x_0)^2}{2} \end{aligned} \quad (3.8)$$

$$g(x) = \frac{d}{dx}f(x) = f'(x_0) + f''(x_0)(x - x_0) = g(x)$$

$g(x) = 0, x = x_1$  的时候是极值,

$$x_1 - x_0 = \frac{f'(x)}{f''(x)} \Rightarrow x_1 = x_0 - \frac{f'(x)}{f''(x)}$$

##### 3.1.2 梯度下降法

找到可微函数的局部最小值

- 1 给定初始值  $x_0, k = 0$
- 2 **while**
- 3     | 计算出  $\frac{\partial f}{\partial x}, \text{cost}$
- 4     |  $x = x - \alpha \left(\frac{\partial f}{\partial x}\right)$
- 5     | **if**  $\text{cost} < \varepsilon$
- 6         | **break**
- 7 **end**

$$\begin{aligned}\theta(j)' &= \theta(j) - \alpha \frac{\partial}{\partial x_j} f(x) \quad \& \quad \text{每一个参数都更新完再下一步} \\ \theta(j) &= \theta(j)'\end{aligned}\tag{3.9}$$

容易走出锯齿路线，从而增加迭代次数。

### 3.1.3 高斯牛顿法

$$f(x_k + \Delta x) \approx f(x_k) + J(x_k)^T \Delta x$$

我们的目标函数可以近似为：

$$\min \frac{1}{2} \| f(x_k) + J(x_k)^T \Delta x \|_2^2$$

现在，我们将近似的目标函数展开：

$$\begin{aligned}M(\Delta X) &= \frac{1}{2} f(x + \Delta X)^2 = \frac{1}{2} (f(x) + J^T \Delta X)^T (f(x) + J^T \Delta X) \\ &= \frac{1}{2} \left[ \underbrace{f(x)^T + \Delta X^T J}_{\text{E}} \right] \left[ \underbrace{f(x) + J^T \Delta X}_{\text{F}} \right] \\ &= \frac{1}{2} \left[ \underbrace{\|f(x)\|^2}_{\text{A}} + \underbrace{f(x)^T J^T \Delta X}_{\text{B}} + \underbrace{\Delta X^T J f(x)}_{\text{C}} + \underbrace{\Delta X^T J J^T \Delta X}_{\text{D}} \right]\end{aligned}\tag{3.10}$$

$$\begin{aligned}dC &= d \operatorname{Tr}[f(x)^T J^T \Delta X] = \operatorname{Tr}[d(f(x)^T J^T \Delta X)] \\ &= \operatorname{Tr}[f(x)^T J^T d\Delta X] \Rightarrow \frac{\partial C}{\partial \Delta X} = J f(x)\end{aligned}$$

$$\begin{aligned}\frac{\partial M(\Delta X)}{\partial \Delta X} &= \frac{1}{2} \left( 0 + J f(X) + J f(x) + \underbrace{2(J J^T \Delta X)}_{\text{定理 2.2.1.3(5)}} \right) \\ &= J f(x) + J J^T \Delta X = 0\end{aligned}$$

$$H \Delta X = g \quad \& \quad H = J J^T \quad \& \quad g = -J f(x)$$

所以高斯牛顿法的步骤是

```

1  给定初始值  $x_0, k = 0$ 
2  while
3      计算出  $J(x_k), f(x_k)$  &  $H = J J^T$  &  $g = -J f(x)$ 
4      使用  $H \Delta X = g$  求出  $\Delta x$ 
5      if  $\Delta x < \varepsilon$ 
6          | break
7      else
8          |  $x_{k++} = x_k + \Delta x$ 
```

9 **end**

它的缺点是要求 $H$ 矩阵可逆, 而且计算量大, 有时候可能无解。并且 $\Delta x$ 过大会导致其局部近似不精确, 严重的时候, 可能无法保证迭代收敛。同时也会锯齿状增大迭代次数(和梯度下降一样)。

### 3.1.3.1 列文伯格-马夸特法(LM)

为了避免其迭代次数过长的缺点, 在高斯牛顿的基础上进行优化, 提出一个信赖区域。

$$\rho = \frac{f(x + \Delta x) - f(x)}{J^T \Delta x}$$

如果它接近一就不需要更改, 如果过大就需要缩小步长, 如果过小就需要增大步长, 这样的话, 就可以动态调整步长了。最优化问题变为

$$\min \frac{1}{2} \|f(x) + J^T \Delta x\|_2^2 \quad s.t. \quad \|D \Delta x\|_2^2 < \mu$$

构建拉格朗日函数<sup>7</sup>

$$L(\Delta x, \lambda) = \frac{1}{2} \|f(x) + J^T \Delta x\|_2^2 + \lambda (\|D \Delta x\|_2^2 - \mu)$$

$$\frac{\partial L(\Delta x, \lambda)}{\partial \Delta x} = J f(x) + J J^T \Delta x + \lambda \frac{\partial (\Delta x^T D^T D \Delta x)}{\partial \Delta x} = J f(x) + J J^T \Delta x + \lambda D^T D \Delta x$$

之前的 $H$ 变为 $J J^T + \lambda D^T D$ , 求解步骤变为

```
1 给定初始值  $x_0, k = 0$ 
2 while
3   计算出  $J(x_k), f(x_k)$  &  $H = J J^T + \lambda D^T D$  &  $g = -J f(x)$ 
4   计算出  $\Delta x$ 
5   计算  $\rho_k = \frac{f(x + \Delta x) - f(x)}{J^T \Delta x}$ 
6   if  $\rho_k < \frac{1}{4}$ 
7      $\Delta x_k = \frac{1}{4} \Delta x_k$ 
8   else
9     if  $\rho_k > \frac{3}{4}$ 
10       $\Delta x_k = \min(2 \Delta x_k, \mu)$ 
11    else
12       $\Delta x_k = \Delta x_k$ 
```

---

<sup>7</sup>目标函数为  $f$  在约束条件  $g$  下的极值与其拉格朗日函数的极值相同。 $\lambda$  被称为拉格朗日算子



```

13  | if  $\rho_k > \xi$ 
14  |    $x_{k+1} = x_k + \Delta x$ 
15  | else
16  |    $x_{k+1} = x_k$ 
17  |  $k=k+1$ 
18  | if  $\Delta x_k < \varepsilon$ 
19  |   break
20 end

```

### 3.1.3.2 随机梯度下降法

### 3.1.4 Example

## 4 概率论+随机过程

### 4.1 随机变量

定义 4.1.1: 定义从  $n$  中取出  $r$  个元素的排列数为  $C_n^r = \frac{n!}{(n-r)!} r!$

定义 4.1.2 (样本空间、随机事件、概率频率, 常见公理):

| 名称            | 定义                        | 注释       |
|---------------|---------------------------|----------|
| 样本空间 $\Omega$ | 全部事件的空间                   | 所有可能的结果  |
| 事件 $A$        | 样本空间的子集                   | 可能发生的事件  |
| 概率 $P$        | 事件发生的可能性                  | 事件发生的可能性 |
| 事件独立          | $P(\Pi A_i) = \Pi P(A_i)$ |          |
| 条件概率          | $P(A B) = P(AB)/P(B)$     |          |

一些基本概率公理

(全概率公式)  $P(A) = \sum_{i=1}^n P(AB_i)$  &  $B_i$  是样本空间的分割

(乘法公式)  $P(AB) = P(A|B)P(B)$

(贝叶斯公式)  $P(B_i|A) = \frac{P(AB_i)}{P(A)} = P(B_i|A) = \frac{P(AB_i)}{\sum_{i=1}^n P(AB_i)} = \frac{P(AB_i)}{P(A|B_i)P(B_i)}$

常见的分布如下

## 5 最优化

### 5.1 拉格朗日乘数法

一个函数的极值可以通过驻点来求解, 驻点不一定是极值点, 有可能是鞍点。

## 5.2 PCA

先推导二维的 PCA

计算一维数据的方差

$$s^2(X) = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

对于二维数据有协方差

$$\text{cov}(X, Y) = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

协方差矩阵  $C$  其实是  $(X_1 = X - \bar{X})$

$$C = \frac{1}{n-1} X_1^T X_1$$

定义一个投影方向  $v = (x_0, y_0)$  st  $x_0^2 + y_0^2 = 1$

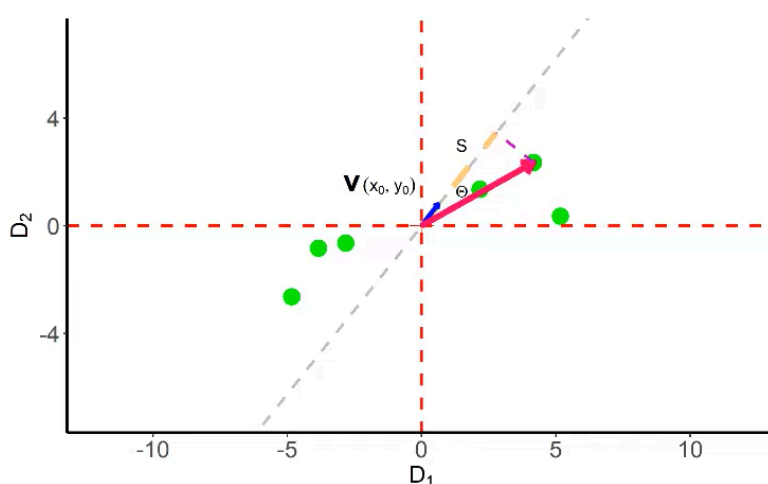


图 5.6: 示意图

$$S = \vec{v}\vec{x} = |\vec{x}| \cos \theta$$

在这个方向投影后的长度的方差其实可以表示为

$$\frac{1}{n-1} \sum S^2 = \frac{1}{n-1} (\vec{v} X_1^T) (\vec{v} X_1^T)^T = \vec{v} \frac{X_1^T X_1}{n-1} \vec{v}^T = \vec{v} C \vec{v}^T$$

最优化方差最小值

$$J = \vec{v} C \vec{v}^T \text{ st } \vec{v} \vec{v}^T = 1$$

$$F(\vec{v}) = \vec{v} C \vec{v}^T - \lambda(1 - \vec{v} \vec{v}^T)$$

$$\frac{\partial}{\partial v} F(\vec{v}) = 0 \Rightarrow 2Cv^T - 2\lambda v^T = 0$$

$$\left( \frac{\partial}{\partial v} f(x)v = f(x)^T, \frac{\partial}{\partial v} A^T v A = Av + A^T v \right), C = C^T$$

C 是实对称矩阵并且使用矩阵求导定理 2.2.1.3

$$Cv^T = \lambda v$$

对 C 做特征值分解，得到两个特征向量 PC1, PC2




图 5.7: PC1 PC2 示意图

## TODOs

### 6 一些其他概率论知识

## 参考文献

1. 杨明 & 刘先忠. 矩阵论. (华中科技大学出版社, 2003).
2. Strang, G. *Linear Algebra and Its Applications 4th ed.* (2012).
3. Akritas, A. G. & Malaschonok, G. I. Applications of Singular-Value Decomposition (SVD). *Mathematics and Computers in Simulation* **67**, 15–31 (2004)
4. 维基百科. 正交矩阵. <https://zh.wikipedia.org/w/index.php?title=%E6%AD%A3%E4%BA%A4%E7%9F%A9%E9%98%B5&oldid=84256160> (2024)
5. 李湘宁, 贾宏志, 张荣福 & others. 工程光学. 108–110 (科学出版社, 2022).